



**Universidade Federal de São João del-Rei
Documentação do Código**

**Eduardo Monteiro Costa Pires
Mateus Nunes**

**Aplicações de modelos de linguagem em Processamento de Linguagem
Natural (PLN)**

**São Joao del-Rei
2025**

SUMÁRIO

- 1 Introdução3**
 - 1.1 Justificativa da Escolha do Modelo e Abordagem 3
- 2 Implementação3**
 - 2.1 Abordagem de Extração de Características (Embeddings)..... 3
 - 2.2 Abordagem de Classificação..... 3
 - 2.3 Tratamento do Desbalanceamento de Classes com o SMOTE 4
- 3 Avaliação de Desempenho4**
 - 3.1 Análise Comparativa: Antes e Depois do SMOTE 5
 - 3.2 Métricas Finais de Desempenho 8
- 4 Relatório Técnico9**
 - 4.1 Resultados e Discussão 9
 - 4.2 Considerações Finais 10
 - 4.3 Aprendizados e Desafios: 10
 - 4.4 Limitações e Trabalhos Futuros: 10
- 5 Exemplos de Testes11**

1 Introdução

1.1 Justificativa da Escolha do Modelo e Abordagem

Para a resolução do problema de classificação de faixa etária a partir de sinopses de filmes, foi adotada uma abordagem híbrida que combina um modelo de linguagem pré-treinado para a extração de características (embeddings) com um classificador de aprendizado de máquina tradicional. A seguir, detalhamos e justificamos cada escolha.

2 Implementação

2.1 Abordagem de Extração de Características (Embeddings)

Em vez de treinar um modelo de linguagem do zero, optamos por utilizar um modelo pré-treinado da biblioteca Sentence-Transformers. A escolha específica foi o sentence-transformers/all-mpnet-base-v2.

Justificativa:

- **Riqueza semântica:** Modelos como o MPNet são treinados em vastos volumes de texto e aprendem a converter sentenças em vetores numéricos (embeddings) que capturam o significado semântico do texto. Isso é superior a outros métodos mais antigos, como o Bag-of-Words ou o TF-IDF, pois compreende o contexto e a relação entre as palavras. Por exemplo, ele entende que "garoto corajoso", "jovem destemido" e "menino valente" são semanticamente parecidos.
- **Maior eficiência e desempenho:** O modelo all-mpnet-base-v2 é um dos modelos de uso geral com melhor performance na plataforma Sentence-Transformers. Ele oferece um excelente equilíbrio entre velocidade de inferência e qualidade dos embeddings, tornando-o ideal para gerar representações ricas das sinopses sem a necessidade de um hardware extremamente poderoso.
- **Generalização:** Por ser um modelo de uso geral, ele pode ser robusto para diferentes domínios, adaptando-se bem a sinopses de filmes de diversos gêneros (comédia, terror, drama, etc.), como a ideia do nosso problema pede.

2.2 Abordagem de Classificação

Uma vez que as sinopses foram convertidas em vetores numéricos (embeddings), utilizamos o classificador LightGBM (LGBMClassifier) para treinar o modelo de predição por motivos de:

- **Performance em Dados Tabulares:** Os embeddings transformam nosso problema de texto em um problema de classificação de dados tabulares (onde cada linha é um filme e as colunas são as dimensões do vetor). O LightGBM é um algoritmo de Gradient Boosting conhecido por sua alta performance, rapidez de treinamento e eficiência no uso de memória, superando frequentemente outros algoritmos em tarefas de classificação com dados estruturados.

- **Mais estável:** O LightGBM é menos suscetível a overfitting do que outros modelos de boosting quando bem parametrizado e lida bem com um grande número de características (as dimensões do embedding).

2.3 Tratamento do Desbalanceamento de Classes com o SMOTE

Analisando inicialmente o conjunto de dados escolhido (`amazon_prime_movies.csv`) foi reveado um forte desbalanceamento entre as classes de `maturity_rating`. Categorias como "Livre" e "7+" tinham muito menos amostras do que categorias mais populares. Modelos treinados em dados desbalanceados tendem a ignorar essas classes minoritárias.

Para mitigar esse problema, foi aplicada a técnica chamada de SMOTE (Synthetic Minority Over-sampling Technique).

Motivação para tal escolha:

- O SMOTE cria amostras sintéticas das classes minoritárias no conjunto de treinamento, em vez de simplesmente duplicar dados existentes. Ele gera novos exemplos que são ligeiramente diferentes dos originais, mas que ainda mantêm as características da classe. Isso força o classificador LGBM a aprender os padrões das classes minoritárias com mais atenção, resultando em um modelo final mais justo e com melhor capacidade de generalização para todas as categorias, como será demonstrado na seção de avaliação de desempenho.

3 Avaliação de Desempenho

A avaliação do modelo foi realizada de forma quantitativa, isto é, utilizando um conjunto de teste separado (com 30% dos dados) que o modelo não viu durante o treinamento. As principais ferramentas de avaliação foram a Matriz de Confusão e o Relatório de Classificação.

Problema enfrentado:

Recall Muito Baixo para 16+ e 7+: O recall para 16+ (**0.35**) e especialmente para 7+ (**0.29**) é muito baixo.

- **O que isso significa na prática?** O modelo **está falhando em identificar a maioria dos filmes que realmente pertencem a essas categorias**. Por exemplo, de cada 10 filmes que são 7+ no seu conjunto de teste, o modelo só conseguiu encontrar cerca de 3. Os outros 7 ele provavelmente classificou como All ou 13+.

O Sintoma do Desbalanceamento: A combinação de **alta precisão e baixo recall** em 16+ e 7+ é um sintoma clássico de desbalanceamento de classes. O modelo não tem exemplos suficientes dessas categorias (support de 158 e 73, respectivamente) para aprender a reconhecê-las com confiança. Por isso, ele só "arrisca" uma previsão para essas classes quando tem certeza absoluta, o que o leva a ignorar muitos casos verdadeiros.

Solução:

Agrupamento de Classes: As cinco classes originais (All, 7+, 13+, 16+, 18+) serão agrupadas em duas:

- **Livre para todos os públicos:** Inclui 'All',.
- **Para a família:** Inclui '7+', '13+'
- **Adulto:** Inclui '16+', '18+'.

Aplicação do SMOTE: Após dividir os dados em treino e teste, o SMOTE será aplicado **apenas no conjunto de treino**. Ele criará exemplos sintéticos da classe minoritária para que o modelo treine com um dataset perfeitamente balanceado.

Nova Rating


- Para a família 2786
- Livre para todos os públicos1762
- Adulto.....1520

3.1 Análise Comparativa: Antes e Depois do SMOTE

Para validar a eficácia da nossa abordagem de balanceamento de dados, comparamos o desempenho do modelo em dois cenários: treinado nos dados originais desbalanceados e treinado nos dados balanceados com o SMOTE.

Cenário 1: Sem SMOTE (Resultado Inicial)

A matriz de confusão inicial evidencia o problema do desbalanceamento.



Alta taxa de confusão entre classes "13+" e "18+"

- 139 instâncias da classe real "18+" foram classificadas erroneamente como "13+".
- Isso representa uma confusão importante entre faixas etárias que deveriam ser bem distintas em termos de conteúdo.
- Essa sobreposição pode indicar que o modelo não está captando bem as características mais específicas dos conteúdos voltados ao público "18+".

Classe "7+" com desempenho fraco

- A classe "7+" teve apenas **21 acertos** corretos, contra **24 erros como "13+", 11 como "18+",** e até mesmo **1 como "16+"**.
- Isso sugere que o modelo tem dificuldade em identificar corretamente a classe "7+", confundindo-a especialmente com a "13+" e "18+".
- Pode ser um reflexo de um desequilíbrio nos dados de treinamento ou de uma baixa representatividade dessa classe.

Classe "16+" com baixo desempenho geral


- A classe "16+" apresenta **56 acertos**, mas também **54 erros como "13+"** e **37 como "18+"**.
- Isso indica um modelo pouco sensível a essa categoria, que parece "diluída" entre as classes vizinhas.
- Pode apontar para falta de características discriminativas entre "16+" e outras faixas etárias próximas.

Alto número de erros em "All" como "13+"

- A classe "All" (Livre para todos os públicos) teve **220 erros como "13+"**, o que é preocupante, pois conteúdos completamente livres estão sendo classificados como não indicados para menores de 13 anos.
- Isso pode gerar implicações práticas graves, como restringir indevidamente conteúdos apropriados para o público infantil.

Cenário 2: Com SMOTE

Após aplicar o SMOTE no conjunto de treino, o desempenho no conjunto de teste melhorou significativamente, como mostra a matriz de confusão final.



Maior acerto geral (melhoria na acurácia)

- A nova matriz mostra um aumento claro nos acertos nas diagonais (valores corretos):
 - **Adulto:** 217 acertos
 - **Livre para todos os públicos:** 231 acertos
 - **Para a família:** 351 acertos
- Isso reflete a **acurácia global de 66%**, representando uma melhora na estabilidade e generalização do modelo.

Melhora expressiva na identificação da classe "Livre para todos os públicos"

- Antes: apenas **444 acertos**, com muitos erros como “13+” (220).
- Agora: **231 acertos** na classe "Livre", com erros mais distribuídos e menos enviesados.
- O modelo está conseguindo **diferenciar melhor conteúdos realmente livres**, evitando confundi-los com faixas etárias restritivas.

Classe “Para a família” teve o maior ganho

- A nova matriz mostra **351 acertos** para essa classe, com melhorias tanto em precisão quanto em recall.
- Antes, essa classe era muito confundida com “13+” e “18+”.
- Agora, o modelo mostra **mais confiança e consistência** na identificação correta desse grupo.

3.2 Métricas Finais de Desempenho

O `classification_report` gerado pelo script (`classificador.py`) para o modelo final (com SMOTE) resume as métricas de precisão, recall e f1-score por classe.

	precision	recall	f1-score	support
Adulto	0.70	0.71	0.71	304
Livre para todos os publicos	0.59	0.65	0.62	353
Para a familia	0.68	0.63	0.65	557
accuracy			0.66	1214
macro avg	0.66	0.67	0.66	1214
weighted avg	0.66	0.66	0.66	1214

- **Precisão (Precision):** Das vezes que o modelo previu uma classe, quantas ele realmente acertou.
- **Revocação (Recall):** De todas as instâncias reais de uma classe, quantas o modelo conseguiu realmente encontrar.
- **F1-Score:** Média harmônica entre precisão e revocação, sendo uma ótima métrica para avaliar o balanço entre as duas.

4 Relatório Técnico

4.1 Resultados e Discussão

O objetivo deste projeto foi desenvolver um sistema capaz de classificar a faixa etária de filmes com base em suas sinopses. A abordagem principal consistiu na utilização do modelo all-mpnet-base-v2 para gerar embeddings semânticos e um classificador LGBM para a predição final.

O principal desafio encontrado foi o forte desbalanceamento de classes no dataset, que inicialmente levou o modelo a ter um desempenho extremamente baixo nas classes minoritárias (7+ e “Livre”), como demonstrado pela primeira matriz de confusão. A implementação da técnica de oversampling SMOTE foi uma ótima solução para o projeto.

Os resultados finais, obtidos após o rebalanceamento, mostram um desempenho consistente do modelo. Alcançamos uma acurácia global de 66% no conjunto de teste. A análise da matriz de confusão e das métricas por classe revela que o modelo é capaz de identificar razoavelmente bem todas as categorias, mesmo diante de possíveis desequilíbrios nos dados.

As métricas de F1-Score indicam um equilíbrio satisfatório entre precisão e recall para as três classes: 0.71 para "Adulto", 0.62 para "Livre para todos os públicos" e 0.65 para "Para a família". O valor médio ponderado do F1-Score ficou em 0.66, o que reforça a estabilidade do modelo em diferentes categorias.

Esses resultados demonstram que o rebalanceamento contribuiu para melhorar o desempenho nas classes menos representadas, tornando o modelo mais robusto e adequado para uso prático.

Além da avaliação quantitativa, o sistema foi implementado com uma interface de linha de comando que permite a predição para novas sinopses, servindo como uma demonstração funcional e qualitativa da aplicação.

4.2 Considerações Finais

Este projeto demonstrou com sucesso a viabilidade de aplicar modelos de linguagem pré-treinados em conjunto com algoritmos de machine learning para resolver problemas práticos de PLN. A combinação de Sentence-Transformers e LightGBM provou ser uma estratégia eficaz e computacionalmente acessível.

4.3 Aprendizados e Desafios:

- O principal aprendizado foi a importância crítica da análise e do pré-processamento dos dados. A aplicação do SMOTE foi mais impactante para o resultado final do que a escolha de um algoritmo de classificação.
- Os dados escolhidos para análise apresentam certa relatividade em sua interpretação, sendo assim, o desenvolvimento de um classificador pode apresentar erros e nem sempre informar de forma correta a faixa etária ideal. Mostrando também a importância de uma base de dados robusta e que apresente diversos exemplos de diferentes faixas etárias, para um melhor treinamento do modelo.

4.4 Limitações e Trabalhos Futuros:

- **Agrupamento de Classes:** A classe "Outros" agrupa diversas categorias (13+, 16+, 18+, etc.), simplificando o problema. Um trabalho futuro poderia tentar classificar todas as categorias originais, o que exigiria um dataset maior ou técnicas de fine-tuning mais avançadas.
- **Fine-Tuning:** Em vez de apenas usar os embeddings "prontos", o modelo all-mpnet-base-v2 poderia ser ajustado especificamente na tarefa de classificação de sinopses. Isso poderia capturar nuances do domínio cinematográfico e potencialmente aumentar a acurácia.
- **Dataset:** O modelo poderia ser treinado com um dataset maior e mais diversificado, incluindo sinopses de outras fontes de streaming ou banco de dados de cinema para melhorar sua generalização.
- **Integração:** esse modelo poderia de alguma forma se juntar com o trabalho um e ser utilizado em conjunto com o sistema de recomendação de filmes antes feito. Para isso seria necessário encontrar um banco de dados que possuísse as sinopses dos filmes além dos dados usados no primeiro trabalho, além de integrar o uso dos dois projetos.

Conclui-se que os objetivos da proposta foram atendidos, resultando em uma aplicação funcional e que satisfaz o proposto. Acreditamos que existe grande possibilidade de melhorias e ajustes importantes que poderiam ser realizados em um estudo mais aprofundado do tema.

5 Exemplos de Testes

Exemplos para a Classe: Para todos os públicos

1. Drama Esportivo Inspirador

- **Texto (Inglês):** "An underdog high school basketball team from a small town, led by a determined new coach, must overcome their personal differences and lack of resources to compete for the state championship. The story focuses on teamwork, perseverance, and community spirit."
- **Saída Adequada:** Para todos os públicos

2. Aventura de Ficção Científica Leve

- **Texto (Inglês):** "A resourceful teenage girl discovers a small, friendly robot that crash-landed in her backyard. She soon finds out the robot is being pursued by a powerful corporation that wants to use its technology. Together, they must outsmart the corporate agents and help the robot return home."
- **Saída Adequada:** Para todos os públicos

3. Comédia Romântica

- **Texto (Inglês):** "A cynical food critic and a relentlessly optimistic chef are forced to work together on a cookbook. Despite their opposite personalities leading to comical clashes in the kitchen, they slowly discover they might be the perfect recipe for each other."
- **Saída Adequada:** Para todos os públicos

4. Documentário sobre a Natureza

- **Texto (Inglês):** "This documentary follows a family of emperor penguins through the harsh Antarctic winter. Narrated with a focus on family bonds and the challenges of survival, it captures the breathtaking beauty and struggle of life in one of the world's most extreme environments."
- **Saída Adequada:** Para todos os públicos

Exemplos para a Classe: Adulto

1. Suspense Psicológico

- **Texto (Inglês):** "A successful author's life unravels when a mysterious stranger accuses him of plagiarizing his life story. As the stranger's psychological torment intensifies, the line between reality and fiction blurs, leading to paranoia, obsession, and a shocking, violent climax."
- **Saída Adequada:** Adulto

2. Drama Policial Intenso

- **Texto (Inglês):** "Two detectives with conflicting methods hunt a serial killer who stages his victims in elaborate, grotesque tableaux. The investigation drags them into the city's corrupt underworld, featuring graphic crime scenes and a pervasive sense of dread."
- **Saída Adequada:** Adulto

3. Filme de Guerra Realista

- **Texto (Inglês):** "During the height of a brutal war, a young soldier is tasked with a near-suicidal mission through enemy territory. The film depicts the grim realities of conflict with unflinching, graphic sequences of combat, intense suffering, and the psychological toll of warfare."
- **Saída Adequada:** Adulto

4. Ficção Científica Distópica

- **Texto (Inglês):** "In a dystopian future where human consciousness can be digitized and transferred between bodies, a former soldier is hired to solve a high-profile murder. His investigation uncovers a conspiracy that challenges the very nature of identity and mortality, involving intense and bloody action sequences."
- **Saída Adequada:** Adulto